Resumo desenvolvimento ISA AXA/PSW

20/03/2026

# 1 - Contexto

Necessidade sistema de **classificação** e **ranqueamento** de cotações em termos de potencial de aprovação, implementado em ambiente Databricks.

# 2 - Desenvolvimento

A solução proposta atualmente segue uma premissa de desenvolvimento de abordagens de ML tradicional, embora seja pertinente estudo de demais abordagens. A atual segue o padrão do que estava sendo implementado desde o início do projeto ISA.

Essencialmente, o cerne do sistema é baseado em modelos de classificação que produzem um “score”, que representa a probabilidade/potencial de emissão de cotação. A partir deste score, podem ser ranqueadas cotações e analisados resultados dos modelos. A variável, que representa o score, gerada pelos modelos, é chamada de *p_emitida.*

A seguir, segue um panorama do estado de desenvolvimento atual.

## 2.1 - Implementado

Estrutura para pipeline de treinamento em MLflow para desenvolvimento e ciclo de vida de modelos/sistemas de ranqueamento de cotações

- Transparente e observável, especialmente para acompanhamento de **regras de negócio** e **arquiteturas de treinamento**
- Comparável, já que fornece visualização que facilita e traz velocidade para desenvolvimento e alinhamento de planos de ação entre área de negócios/estratégica AXA e time de dados AXA/PSW
- Possibilidade de comparação com modelos desenvolvidos anteriormente, para demais segmentações, em uma estrutura MLflow antiga que deu lugar à atual
- Acessível para consulta e acompanhamento time de dados AXA, que tem acesso total ao ambiente Databricks
- Contempla detalhes de execuções (runs) desde etapa de ingestão dos dados à camada Bronze Databricks até Feature Engineering, treino e comparação de resultados

## 2.2 - Em andamento

- Na última iteração time de dados AXA/PSW, foram definidos testes (novas regras de negócio/processamento e arquitetura de treinamento) que seriam realizados para análise e comparação de resultados. Hoje, temos estes resultados (v10.0.0) apenas para a segmentação SEGURO_NOVO_MANUAL, embora seja direta e rapidamente

replicável para demais segmentações. Portanto, a materialização dos modelos para as demais segmentações será realizada como prioridade para termos ponto de partida para futuras agendas com área de negócio
- Reports automatizados para envio como documentação de avanço à área de negócio
- Criação de estrutura análoga ao pipeline de treinamento atual MLflow, mas para **inferência** dos modelos treinados previamente (será criado um pipeline de distribuição)
- Análises base de dados recebida e incorporação em novos testes (Feature Engineering, definição de novas regras de negócio a serem testadas e aprimoramento das atuais)

## 2.3 - Próximos passos sugeridos/mapeados

- Análise de capacidade e conversão do time comercial para interpretar ganho no uso dos modelos propostos (possibilitar análises de performance e resultados mais realistas e aderentes)
- Teste com novos modelos/arquiteturas
- Execuções livres e observáveis de exploração e teste, utilizando a estrutura MLflow já desenvolvida
- Validação do desenvolvimento e definição de direcionamento entre AXA/PSW (seguir ou não com arquitetura, estrutura e abordagens atuais, etc)

# 3 - Detalhamento do desenvolvimento

Breve demonstração da estrutura do projeto e artefatos desenvolvidos.

## 3.1 - Estrutura notebooks

Notebooks por etapa, unificados e configuráveis por execução. Cada notebook representa uma etapa na estrutura do MLflow:

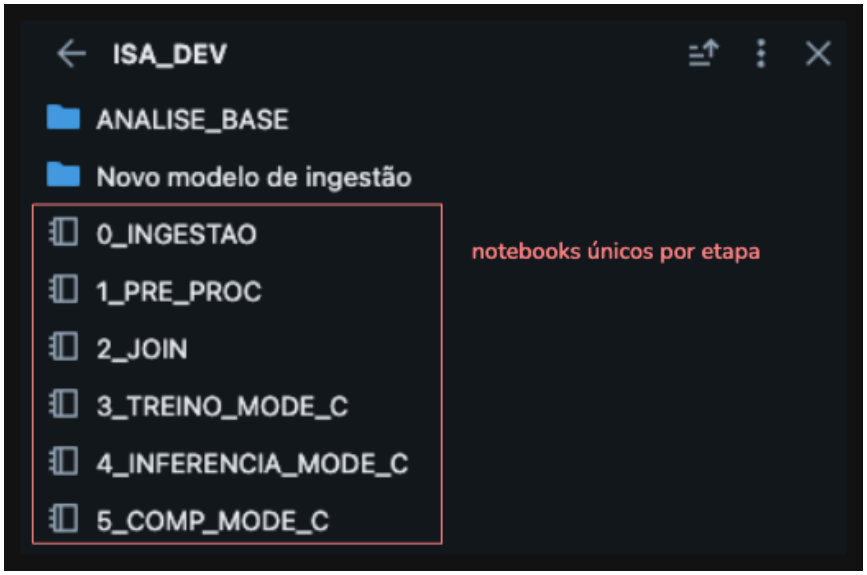

## 3.2 - Estrutura MLflow (pipeline de treinamento já implementado)

Aqui, cada etapa de execução (*_timestamp) representa um teste observável.

| | | | Parameters | | Tags |
|---|---|---|---|---|---|
| Run Name | Created | Duration | mode_code | seg_target | versao_ref |
| T_PR_COMP | 12 days ago | 12.5d | - | - | - |
| T_PR_INFERENCIA | 12 days ago | 12.5d | - | - | - |
| T_PR_TREINO | 12 days ago | 12.5d | - | - | - |
| T_PR_JOIN | 17 days ago | 15.9d | - | - | - |
| T_PR_PRE_PROC | 20 days ago | 18.7d | - | - | - |
| T_PR_INGESTAO | 20 days ago | 18.8d | - | - | - |

Dentro destas PRs, são logadas as execuções.

### 3.2.1 - Etapas iniciais de ingestão > pré-processamento > join tabelas de cotações + corretor (T_PR_INGESTAO, T_PR_PRE_PROC, T_PR_JOIN)

| | | | Parameters | | Tags |
|---|---|---|---|---|---|
| Run Name | Created | Duration | mode_code | seg_target | versao_ref |
| T_PR_COMP | 12 days ago | 12.5d | - | - | - |
| T_PR_INFERENCIA | 12 days ago | 12.5d | - | - | - |
| T_PR_TREINO | 12 days ago | 12.5d | - | - | - |
| T_PR_JOIN | 17 days ago | 15.9d | - | - | - |
| T_JOIN_20260318_112204 | 2 days ago | 24.9s | - | - | - |
| T_JOIN_20260310_163401 | 9 days ago | 21.9s | - | - | - |
| T_PR_PRE_PROC | 20 days ago | 18.7d | - | - | - |
| T_PRE_PROC_20260318_111912 | 2 days ago | 50.5s | - | - | - |
| T_PRE_PROC_20260310_163104 | 9 days ago | 45.5s | - | - | - |
| T_PR_INGESTAO | 20 days ago | 18.8d | - | - | - |
| T_INGESTAO_20260318_110703 | 2 days ago | 39.4s | - | - | - |
| T_INGESTAO_20260310_143820 | 9 days ago | 20.5s | - | - | - |

Nestas etapas, são essencialmente capturadas informações de profiling e regras de negócio/pré-processamento aplicadas ao longo do pipeline.

### 3.2.2 - Etapas de treinamento e inferência em dados de hold-out para análise preliminar de performance (T_PR_TREINO e T_PR_INFERENCIA)

| | | | Parameters | | Tags |
|---|---|---|---|---|---|
| Run Name | Created | Duration | mode_code | seg_target | versao_ref |
| T_PR_COMP | 12 days ago | 12.5d | - | - | - |
| T_PR_INFERENCIA | 12 days ago | 12.5d | - | - | - |
| T_INF_20260320_110015 | 1 hour ago | 1.5min | C | SEGURO_NOVO_MANUAL | V10.0.0 |
| T_INF_20260317_144656 | 2 days ago | 1.1min | C | SEGURO_NOVO_MANUAL | V9.0.0 |
| T_PR_TREINO | 12 days ago | 12.5d | - | - | - |
| T_MODE_C | 7 days ago | 7.0d | - | - | - |
| T_TREINO | 7 days ago | 6.9d | - | - | - |
| T_TREINO_20260319_195931 | 4 hours ago | 2.8h | C | SEGURO_NOVO_MANUAL | V10.0.0 |
| T_TREINO_20260316_203342 | 3 days ago | 1.1h | C | SEGURO_NOVO_MANUAL | V9.0.0 |
| T_FEATURE_SELECTION | 7 days ago | 6.4d | - | - | - |
| T_FS_20260319_195931 | 16 hours ago | 18.0min | C | SEGURO_NOVO_MANUAL | V10.0.0 |
| T_FS_20260316_203342 | 3 days ago | 19.4min | C | SEGURO_NOVO_MANUAL | V9.0.0 |
| T_PRE_PROC_MODEL | 7 days ago | 6.3d | - | - | - |
| T_PRE_PROC_MODEL_20260319_195931 | 16 hours ago | 19.4s | C | SEGURO_NOVO_MANUAL | V10.0.0 |
| T_PRE_PROC_MODEL_20260316_203342 | 3 days ago | 38.1s | C | SEGURO_NOVO_MANUAL | V9.0.0 |
| T_PR_JOIN | 17 days ago | 15.9d | - | - | - |
| T_PR_PRE_PROC | 20 days ago | 18.7d | - | - | - |
| T_PR_INGESTAO | 20 days ago | 18.8d | - | - | - |

A etapa de treinamento (T_PR_TREINO), acomoda 3 sub-etapas:

- T_PRE_PROC_MODEL: Etapa complementar de regras aplicadas ao set de treinamento e validação
- T_FEATURE_SELECTION: Atualmente utilizando 3 modelos para análise de importância de variáveis para treinamento, embora estas possam ser definidas de forma arbitrária para a etapa de treinamento
- T_TREINO: Etapa de treinamento, hoje sendo utilizado um modelo de classificação (GBT), embora possam ser testados demais arquiteturas. O pipeline de treinamento contempla:
    - Cross Validation para análise de estabilidade dos resultados
    - Treinamento em grid arbitrário de parâmetros

Após a materialização dos modelos em T_PR_TREINO, é feita a inferência (T_PR_INFERENCIA) em dados de hold-out, para posterior análise de performance.

### 3.2.3 - Etapa de comparação de modelos para uma mesma run/execução (T_PR_COMP_

| | | | Parameters | | Tags |
|---|---|---|---|---|---|
| Run Name | Created | Duration | mode_code | seg_target | versao_ref |
| T_PR_COMP | 12 days ago | 12.5d | - | - | - |
| T_COMP_20260320_110639 | 1 hour ago | 16.7s | C | SEGURO_NOVO_MANUAL | V10.0.0 |
| T_COMP_20260318_100806 | 2 days ago | 35.7s | C | SEGURO_NOVO_MANUAL | V9.0.0 |
| T_PR_INFERENCIA | 12 days ago | 12.5d | - | - | - |
| T_PR_TREINO | 12 days ago | 12.5d | - | - | - |
| T_PR_JOIN | 17 days ago | 15.9d | - | - | - |
| T_PR_PRE_PROC | 20 days ago | 18.7d | - | - | - |
| T_PR_INGESTAO | 20 days ago | 18.8d | - | - | - |

Nesta etapa, são sumarizadas visualizações e informações referentes à performance do modelo, sob ponto de vista estatístico, ajustadas para o uso do sistema como rankeador de cotações de potencial de aprovação.

Tomando como exemplo a execução *T_COMP_20260320_110639,* temos, como artefatos gerados:

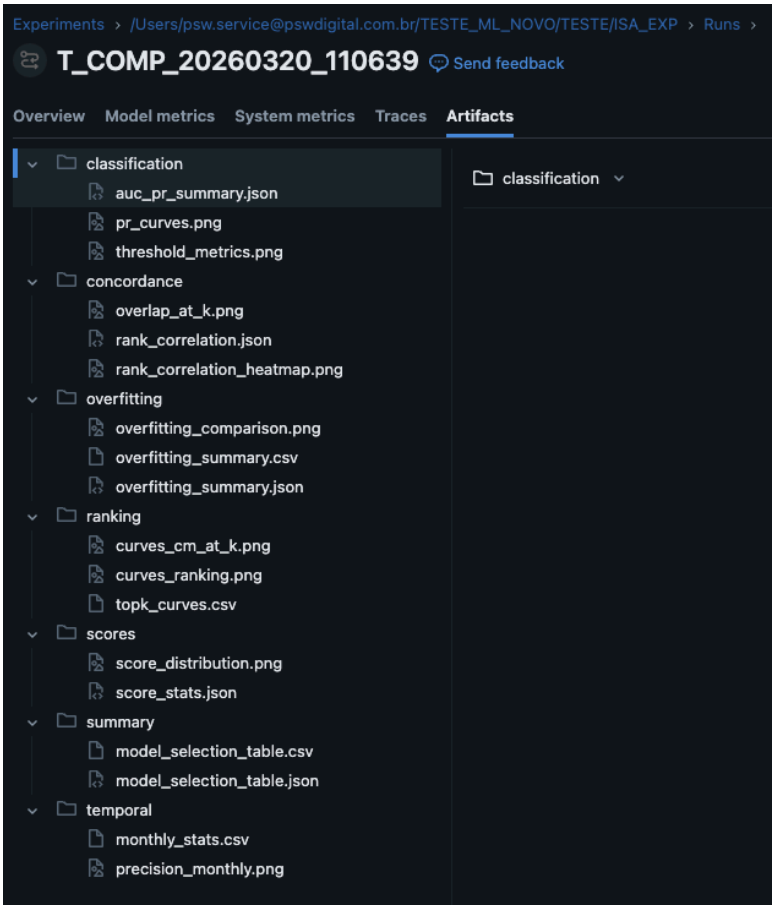

Diversas análises podem ser geradas e discutidas em conjunto com área de negócio para refinamento e maior assertividade na previsão do comportamento dos modelos com dados novos (de produção).

Na execução de exemplo (*T_COMP_20260320_110639*), foram gerados 4 modelos no grid, variandoparâmetros:

- d4_s01
- d6_s01
- d4_s005
- d6_s005

Nesta execução, os atributos alimentados como features ao modelo de classificação (GBT) foram:

"HR_2025_detalhe",
"DS_PRODUTO_NOME",
"DIAS_INICIO_VIGENCIA",
"VL_PREMIO_LIQUIDO",
"DIAS_COTACAO",
"VL_PRE_TOTAL",
"QTD_EMITIDO_2025_detalhe",
"DIAS_VALIDADE",
"QTD_COTACAO_2025_detalhe"

Cada análise desta etapa compara os modelos gerados através de um grid de treinamento, em uma mesma execução. Nas visualizações que seguem, não é adicionada explicação detalhada sobre métricas e resultados. Dentre o que é analisado hoje, temos:

**Curva Precision x Recall**, que representa o trade-off entre um modelo capaz de prever corretamente o desfecho de cotações e de capturar cotações que, de fato, converteram em Emitidas

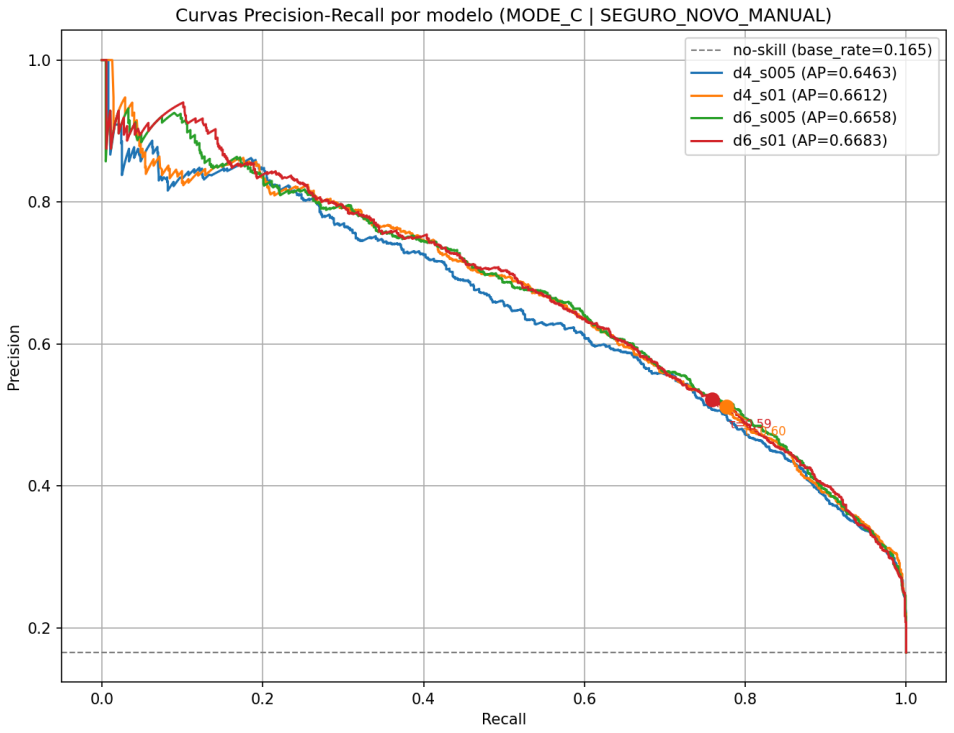

## **Concordância de modelos** no grid de execução

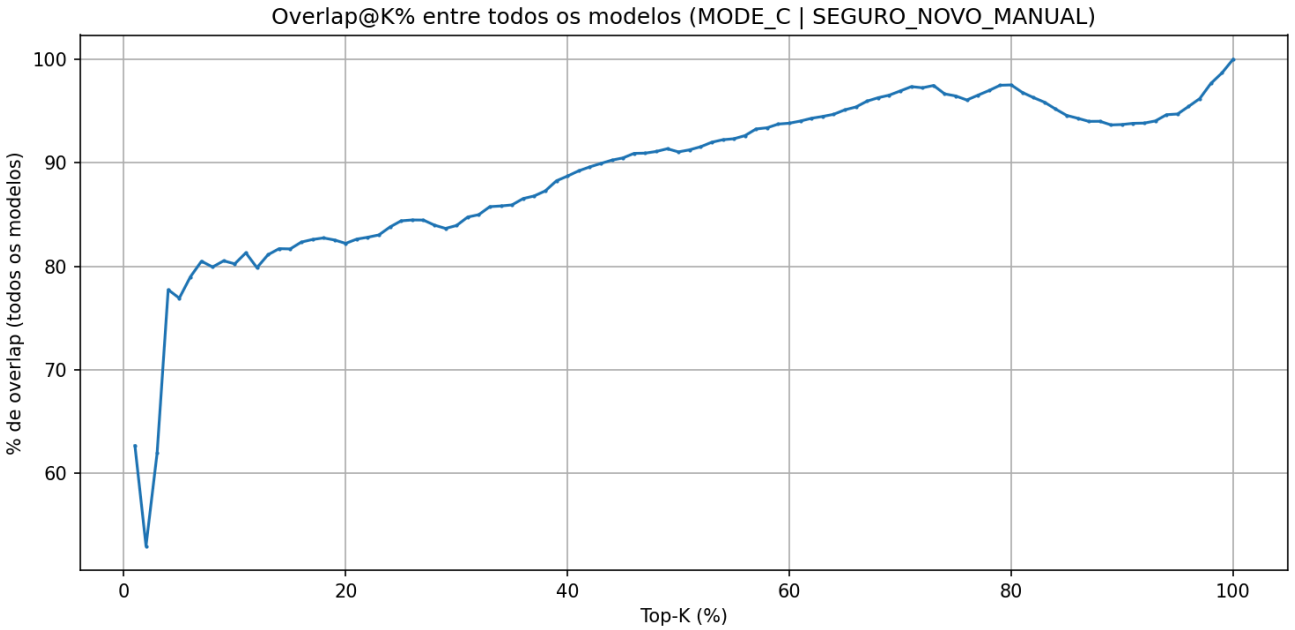


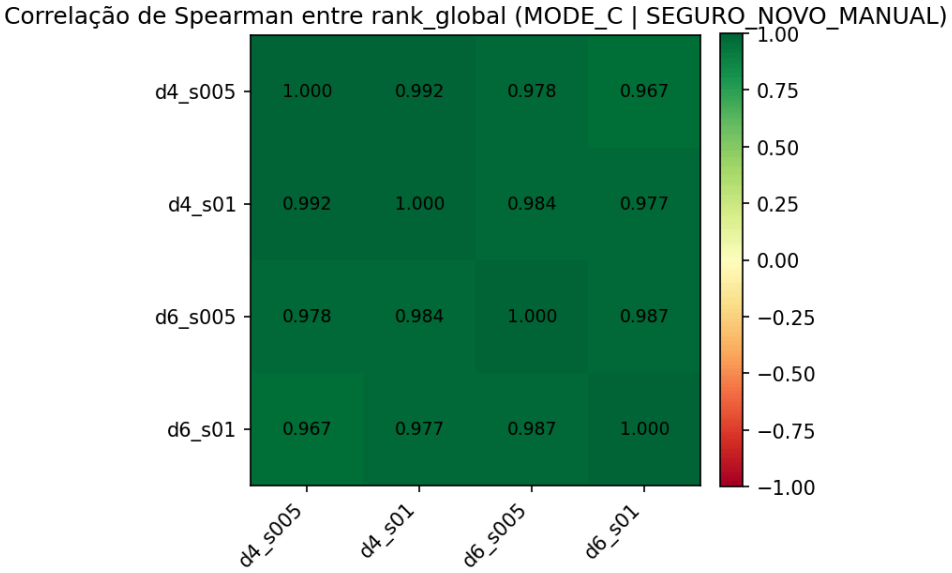

**Matriz de confusão** ao longo de faixas de capacidade hipotéticas do time comercial

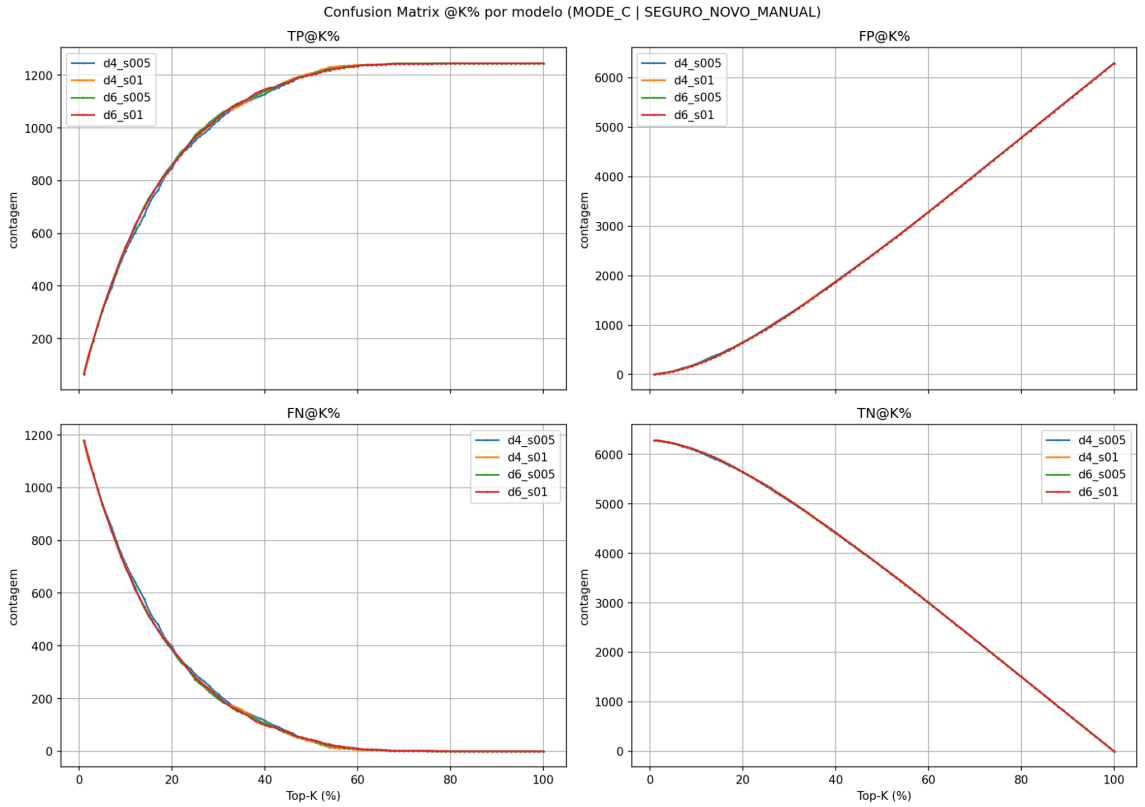


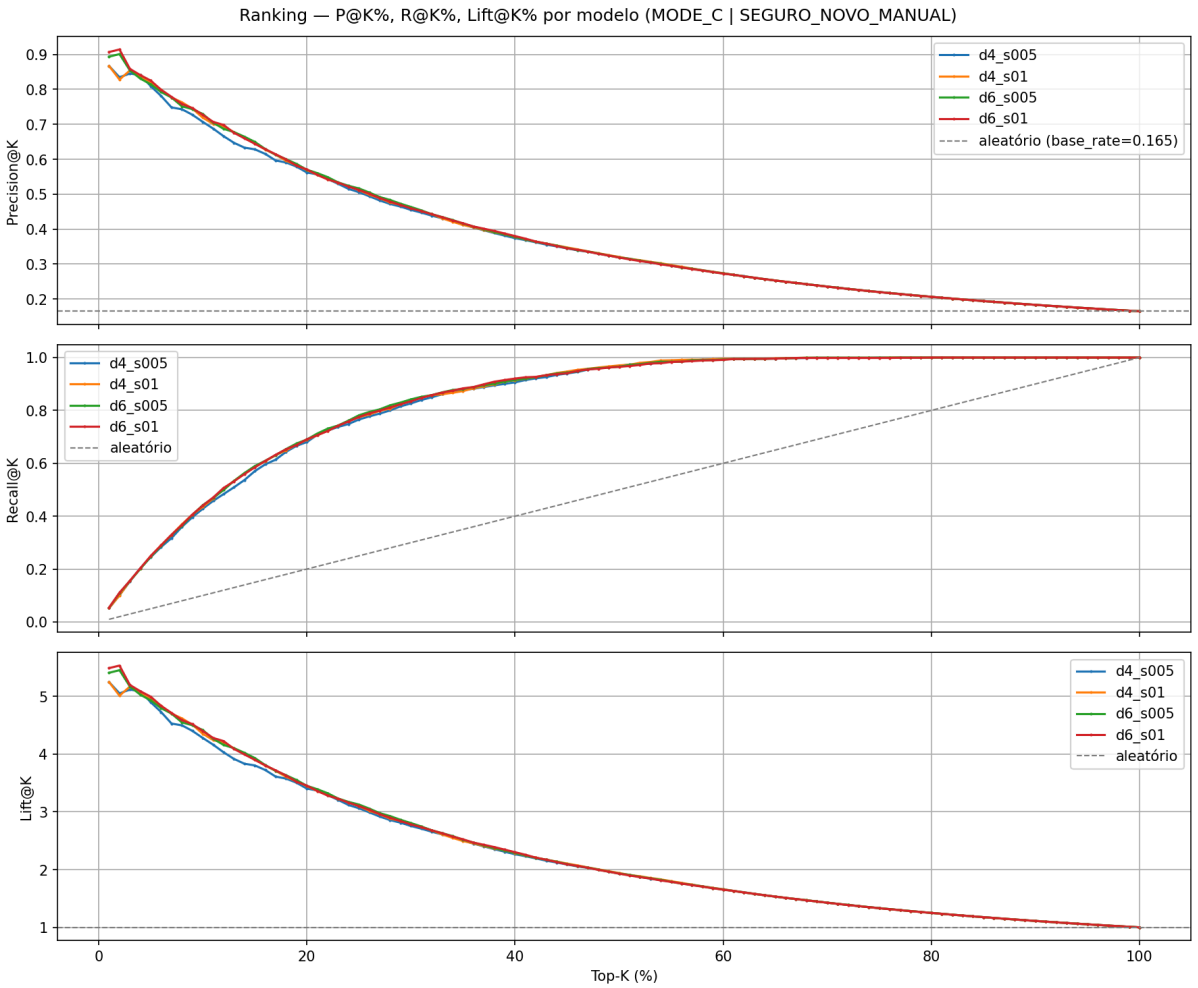
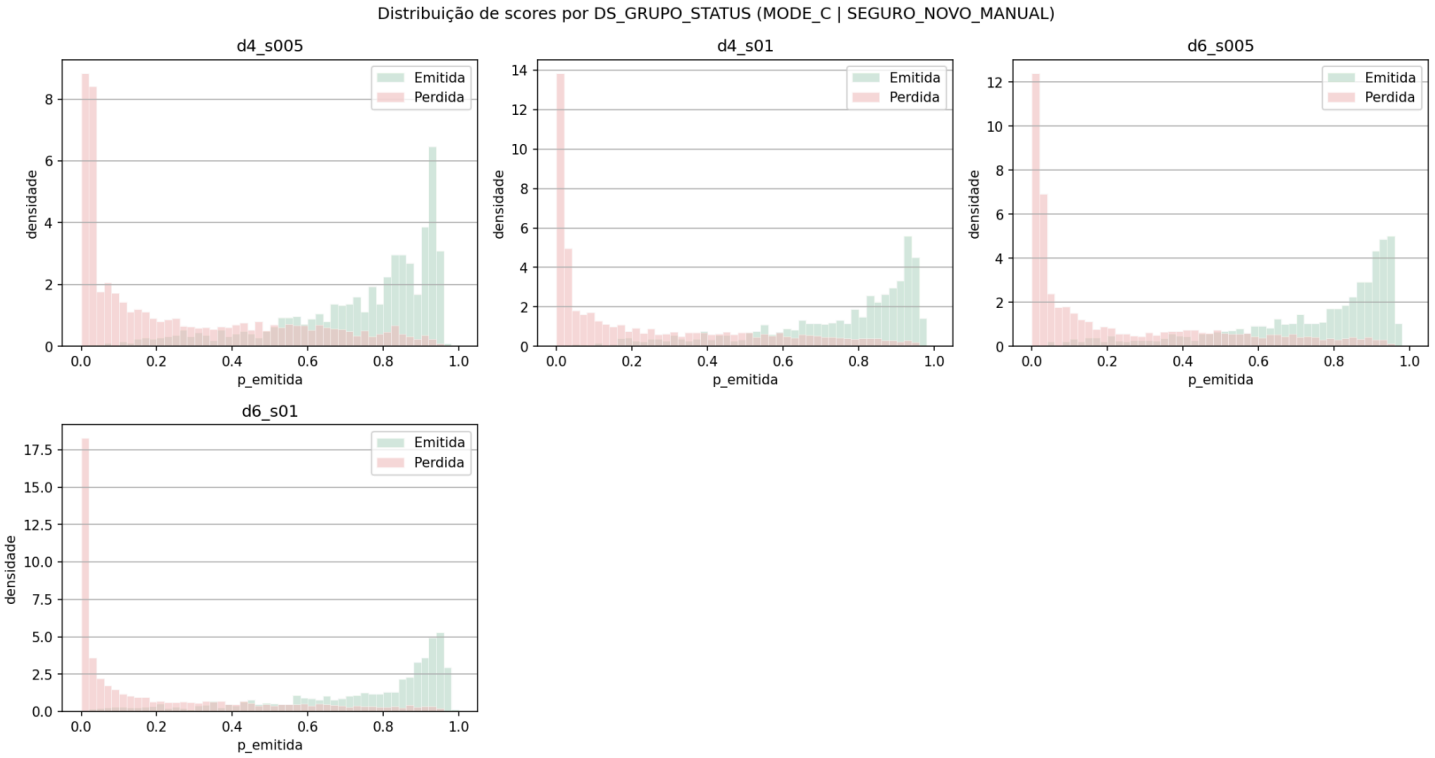
**Distribuição dos scores** estratificada por desfecho real das cotações